

Dinámica de la marcha para el diagnóstico diferencial de enfermedades neurodegenerativas

Análisis exploratorio · Entrega P1

Luis Renato Alvarez Ccopa Andersson Chiroque Silva
David Teofilo Orihuela Serafin Jeraldine Dione Rojas Vargas

Universidad de Ingeniería y Tecnología

Machine Learning · 2026-1

El problema

Tres enfermedades neurodegenerativas destruyen el control motor por mecanismos distintos:

Parkinson

Degradación de ganglios basales → marcha rígida, pasos cortos

Huntington

Movimientos coreicos involuntarios → marcha errática

ELA

Daño a la motoneurona → debilidad y compensación

El diagnóstico diferencial temprano es difícil y descansa en evaluación subjetiva.

Una marcha instrumentada de 5 minutos es **barata, no invasiva y repetible**.

Pregunta central

¿La dinámica temporal de la marcha distingue *entre* patologías, o solo separa enfermos de sanos?

Clasificación supervisada multiclase, con el **sujeto** como unidad de análisis.

- X** Descriptores de la serie de intervalos de zancada (~ 250 por sujeto)
 - y** Control / Parkinson / Huntington / ELA
 - n** 64 sujetos
- Métrica: exactitud balanceada y F_1 macro

Preguntas de investigación

- PI1** ¿Se discrimina entre patologías?
- PI2** ¿Cuánto sesgo introduce evaluar por zancada en vez de por sujeto?
- PI3** ¿Es patología o son confusores (edad, sexo, velocidad)?

Los datos

Gait in Neurodegenerative Disease Database — PhysioNet, licencia abierta ODC-By 1.0

Protocolo: 5 minutos de marcha continua, pasillo de 77 m, resistores de fuerza bajo cada pie, 300 Hz. Los 64 registros son idénticos en duración y muestreo.

Tres niveles por sujeto

- Señal cruda de fuerza (90 000 muestras)
- Serie derivada: 13 medidas por zancada
- Metadata clínica

Grupo	<i>n</i>	Edad	Vel. (m/s)
Control	16	39.3	1.35
Parkinson	15	66.8	1.00
Huntington	20	46.7	1.15
ELA	13	55.6	1.05

Total: **15 160 zancadas**

Hallazgo 1 — La metadata no se puede leer de frente


Cuatro defectos que un `read_csv` directo no sobrevive:

1. **Un salto de línea parte un registro.** `hunt20` está dividido en dos filas → el parser devuelve **65 filas para 64 sujetos**.
2. **Los faltantes son la cadena literal MISSING** → las columnas dejan silenciosamente de ser numéricas.
3. **La variable objetivo declarada está mal.** Los 13 sujetos con ELA tienen `GROUP = "subjects"` → se pierde la clase ELA.
4. **Una columna, cuatro escalas incomparables.** `Hoehn & Yahr`, capacidad funcional (invertida), meses desde diagnóstico y cero de relleno.


El defecto 4 es una fuga de la variable objetivo

El rango de valores identifica el grupo casi perfectamente. La columna queda excluida del modelado.


Hallazgo 2 — Los grupos no son comparables



27 años de diferencia
control vs. Parkinson



12.5 % vs. 76.9 %
de hombres, control vs. ELA



Velocidad
es consecuencia, no artefacto

Hallazgo 3 — Un registro inutilizable

hunt20 viola alguna regla de validez en el **100 % de sus zancadas**.

	Pie izquierdo	Pie derecho
Intervalo de zancada mediano	0.99 s	42.9 s
Fase de apoyo	61 %	98 %
Fase de balanceo	39 %	2 %
Apoyo doble resultante: de -70% a $+4317\%$ del ciclo		

El canal derecho no registró despegues. Sumado a que su registro empieza 42 s tarde, a que su velocidad es MISSING y a que es el sujeto con la fila partida:

falla de cuatro maneras independientes → se excluye. Quedan 63 sujetos.

Hallazgo 4 — El filtrado determina las conclusiones

Las series se distribuyen **sin filtrar** y contienen zancadas de hasta **55 segundos**.

Grupo	CV sin filtrar	CV filtrado	Factor
Control	0.044	0.041	1.08
Parkinson	0.189	0.074	2.56
Huntington	0.138	0.105	1.32
ELA	0.431	0.063	6.80


Sin filtrar, la ELA aparenta la marcha más inestable: **10 veces** la variabilidad del control.

Tras descartar el 5.9 % de zancadas inválidas del grupo, ese CV cae a 0.063.

El orden se invierte

El grupo más inestable pasa a ser **Huntington**, que es lo consistente con la fisiopatología coreica. En este dataset el filtrado no ajusta los resultados: los determina.

¿Hay señal? (PI1)



Huntington pierde estructura temporal: α de DFA 0.65 vs. 0.88 en control; autocorrelación 0.19 vs. 0.49. Variable *sin memoria*.

ELA compensa: zancada más larga (1.36 s) y más apoyo doble (35%).

Parkinson queda intermedio en casi todo → será la clase más difícil.

Ningún descriptor aislado separa las cuatro clases: la señal es **multivariada y parcial**.

Hallazgo 5 — Fuga de información por sujeto (PI2)

63 sujetos son pocos. La práctica habitual: trocear cada serie en ventanas $\rightarrow \times 8$ filas.

Pero las ventanas de un sujeto comparten fisiología, calzado y sesión: **no son independientes**.

Unidad	Partición	n	Exactitud balanceada
Ventana de 30 zancadas	Aleatoria	482	$0,812 \pm 0,049$
Ventana de 30 zancadas	Por sujeto	482	$0,622 \pm 0,086$
Sujeto	Estratificada	63	$0,642 \pm 0,048$

Mismos datos, mismos descriptores, mismo modelo. La única diferencia es la partición.

19 puntos porcentuales de optimismo puro

La tercera fila es la verificación: evaluar directamente por sujeto da 0.642, que coincide con la estimación agrupada y *no* con la aleatoria. El split agrupado es el estimador correcto.

La cohorte de validación resuelve el confusor de edad

gaitpdb: 165 sujetos con señal (93 Parkinson, 72 control), 16 sensores de fuerza por pie, otro protocolo de captura.

Cohorte	Control	Parkinson	Diferencia	p (Welch)
gaitnidd	39.3 años	66.8 años	+27,5	$3,2 \times 10^{-5}$
gaitpdb	63.7 años	66.3 años	+2,6	0,063

El desbalance por sexo también desaparece: 54.8 % contra 62.4 % de hombres, frente a 12.5 % contra 66.7 % en la cohorte principal.

Deja de ser solo una prueba de generalización

Si el eje Parkinson–control se sostiene donde la edad *no* discrimina, la edad no era el mecanismo. Es el instrumento para responder PI3 en P2.

Sus propios defectos, ya documentados: tabuladores de relleno variables que rompen el parser, talla en centímetros en uno de los tres estudios, un sujeto huérfano con el ID mal escrito, y Hoehn & Yahr y UPDRS como fuga perfecta de la etiqueta.

Limitaciones (PI3)

- **Confusores no corregibles dentro de la cohorte principal.** El grupo control es 27 años más joven y mayoritariamente femenino. La cohorte externa acota el efecto, pero solo para el eje Parkinson-control: Huntington y ELA quedan sin contraparte pareada.
- **Muestra reducida.** 63 sujetos obligan a validación *leave-one-subject-out* e intervalos de confianza amplios.
- **El filtrado es diferencial por clase.** Elimina 260 zancadas en Huntington y 1 en control. Queda abierto si una zancada de 3 s es error del sensor o congelamiento real.
- **Talla y peso no son comparables** entre cohortes: se recolectaron por separado y con convenciones de unidades distintas.

Siguientes pasos — P2

1. **Protocolo de evaluación:** validación agrupada por sujeto (LOSO), búsqueda de hiperparámetros *anidada*, intervalos de confianza por bootstrap.
2. **Baselines:** clase mayoritaria y un baseline clínico que use *solo* la velocidad de marcha. Si los descriptores de dinámica no lo superan, no justifican su complejidad.
3. **Modelos:** regresión logística multinomial regularizada, ensamble de árboles y una CNN 1D sobre la serie cruda.
4. **Validación externa y control del confusor:** entrenar y evaluar el eje Parkinson–control por separado en la cohorte confundida y en la pareada; la diferencia acota el efecto demográfico. Más regresión de severidad UPDRS dentro del grupo de pacientes.
5. **Análisis de confusores:** reentrenar en subgrupos comparables por edad y medir la pérdida.
6. **Interpretación:** importancia por permutación agrupada y matriz de confusión, con foco en Parkinson–ELA.

Gracias

Datos	PhysioNet gaitnidd y gaitpdb (ODC-By 1.0)
Código	repositorio público del proyecto